

Implementación de un modelo cuántico utilizando Qiskit Machine Learning

Aracely Fiorela Corampa Palacios, Dennis

Moises Ccapatinta Queccaño, Cesar

Andersson Saire Hanco, Timoteo Quispe

Merma, Jhon William Huanca Alca, Bruce

Maximo Mamani Gabriel

Universidad Nacional de San Antonio Abad del Cusco

Abstract—El aprendizaje automático cuántico (*Quantum Machine Learning*, QML) surge como una alternativa prometedora frente a las limitaciones de la inteligencia artificial clásica en problemas de alta complejidad computacional. Este trabajo presenta el diseño, implementación y evaluación de un clasificador cuántico variacional (*Variational Quantum Classifier*, VQC) utilizando Qiskit Machine Learning, comparando su desempeño con un modelo clásico de referencia basado en *Support Vector Machine* (SVM).

El estudio se desarrolla bajo un enfoque híbrido cuántico-clásico, empleando el dataset Iris filtrado a dos clases (Setosa y Versicolor) y aplicando un preprocesamiento consistente mediante normalización y división estratificada de los datos. El modelo cuántico se construye a partir de un mapa de características cuántico (ZZFeatureMap), un circuito variacional entrenable (RealAmplitudes) y un optimizador clásico libre de gradientes (COBYLA), mientras que el modelo clásico utiliza una SVM con kernel RBF como línea base de comparación.

Los resultados experimentales evidencian que, si bien el modelo clásico alcanza una mayor precisión y un tiempo de cómputo significativamente menor, el VQC demuestra una capacidad real de aprendizaje y clasificación no aleatoria. Asimismo, el análisis revela las limitaciones actuales del QML, especialmente en términos de costo computacional cuando se emplean simuladores cuánticos, y resalta el potencial futuro de las arquitecturas híbridas cuántico-clásicas en escenarios más complejos.

■ **EN LA ACTUALIDAD**, la inteligencia artificial ha alcanzado avances significativos en áreas como el reconocimiento de patrones, la traducción automática, la conducción autónoma y el diagnóstico médico. Sin embargo, a pesar de estos logros, los modelos clásicos enfrentan limitaciones fundamentales cuando se aplican a problemas de alta complejidad computacional, tales como la simulación molecular, la optimización global y el procesamiento de espacios de búsqueda exponenciales, los cuales pueden requerir años o incluso siglos de cómputo en arquitecturas tradicionales.

Ante este escenario, la computación cuántica emerge como un nuevo paradigma capaz de transformar la forma en que se procesan y analizan los datos. Basada en principios como la superposición y el entrelazamiento cuántico, esta tecnología permite explorar múltiples estados de manera simultánea y capturar correlaciones complejas que resultan inaccesibles para la computación clásica. La convergencia entre estos principios y el aprendizaje automático da lugar al campo del *Quantum Machine Learning* (QML), considerado como la siguiente frontera en la evolución de la inteligencia artificial.

En este contexto, el presente trabajo se centra en el estudio y la implementación de un modelo de aprendizaje automático cuántico de tipo híbrido, específicamente un *Variational Quantum Classifier* (VQC), utilizando el framework Qiskit Machine Learning. El desempeño del modelo cuántico es evaluado y comparado rigurosamente con un modelo clásico bien establecido, una *Support Vector Machine* (SVM), empleando el mismo conjunto de datos, preprocesamiento y métricas de evaluación, con el objetivo de analizar de manera objetiva las capacidades, limitaciones y el potencial real del aprendizaje automático cuántico en la actualidad.

Justificación

La Inteligencia Artificial clásica ha demostrado ser altamente efectiva en múltiples aplicaciones, como el reconocimiento facial, la traducción automática, los sistemas de recomendación y el diagnóstico médico asistido. No obstante, estos enfoques presentan limitaciones significativas cuando se enfrentan a problemas de complejidad exponencial, tales como la simulación molecular, la optimización global de rutas, la

predicción climática de alta precisión y la factorización de grandes números, los cuales exceden la capacidad práctica de las arquitecturas clásicas actuales.

En este contexto, la computación cuántica surge como un nuevo paradigma con el potencial de superar dichas limitaciones, al aprovechar fenómenos propios de la mecánica cuántica como la superposición y el entrelazamiento. La integración de estos principios con el aprendizaje automático da lugar al campo emergente del *Quantum Machine Learning* (QML), el cual promete explorar espacios de características de alta dimensión y abordar problemas intratables para la computación clásica.

La realización de este proyecto se justifica, además, por el crecimiento exponencial del interés académico e industrial en QML, reflejado en el aumento significativo de publicaciones científicas, inversiones globales y la disponibilidad de hardware cuántico accesible a través de plataformas en la nube como IBM Quantum. Este acceso permite que la investigación y experimentación en aprendizaje automático cuántico deje de ser un concepto teórico y se convierta en una realidad práctica.

Asimismo, el proyecto responde a la necesidad de formar profesionales capacitados en tecnologías emergentes, considerando que la demanda de especialistas en computación cuántica y programación cuántica continúa en aumento. La implementación y comparación de un clasificador cuántico variacional (VQC) frente a un modelo clásico de referencia (SVM) no solo permite evaluar de manera objetiva el estado actual del QML, sino que también contribuye a desmitificar expectativas irreales, ofreciendo un análisis honesto de sus ventajas, limitaciones y perspectivas futuras.

Finalmente, este trabajo aporta una implementación reproducible y documentada en español, lo que contribuye a reducir la brecha de recursos educativos disponibles y fomenta una comprensión crítica de las arquitecturas híbridas cuántico-clásicas, consideradas actualmente como el camino más realista para el desarrollo del aprendizaje automático cuántico.

Marco Teórico y Antecedentes

El desarrollo del aprendizaje automático ha estado históricamente ligado a la evolución de la computación clásica, permitiendo avances significativos en tareas como clasificación, regresión, reconocimiento de patrones y análisis predictivo. Sin embargo, a medida que los problemas abordados incrementan su complejidad,

Digital Object Identifier 10.1109/MCE.YYYY.Doi Number

Date of publication DD MM YYYY; date of current version DD MM YYYY

los enfoques clásicos comienzan a enfrentar limitaciones inherentes asociadas al crecimiento exponencial del espacio de búsqueda y al costo computacional requerido para su resolución.

Limitaciones del aprendizaje automático clásico

Los modelos clásicos de Inteligencia Artificial han alcanzado niveles sobresalientes de precisión en aplicaciones prácticas como el reconocimiento facial, la traducción automática y los sistemas de recomendación. No obstante, existen clases de problemas —como la simulación molecular, la optimización global y la factorización de grandes números— que resultan intratables incluso para supercomputadoras clásicas. Estas limitaciones han motivado la exploración de nuevos paradigmas computacionales capaces de superar las barreras del cómputo tradicional.

Entre los algoritmos clásicos más utilizados para clasificación se encuentran las *Support Vector Machines* (SVM), las cuales se caracterizan por su solidez matemática y capacidad de generalización mediante el uso de funciones kernel. A pesar de su eficacia, su desempeño continúa estando restringido por la arquitectura clásica subyacente.

Fundamentos de la computación cuántica

La computación cuántica se fundamenta en principios de la mecánica cuántica, tales como la superposición y el entrelazamiento. El elemento básico de información es el *qubit*, el cual puede representar simultáneamente los estados 0 y 1. Esta propiedad permite que un sistema de n qubits represente 2^n estados de manera paralela, otorgando una capacidad de procesamiento exponencialmente superior a la de los sistemas clásicos.

El entrelazamiento cuántico introduce correlaciones no clásicas entre qubits, lo que posibilita la representación de relaciones complejas en los datos. El procesamiento de la información se realiza mediante circuitos cuánticos compuestos por puertas cuánticas, tales como la puerta Hadamard, puertas de rotación parametrizadas y puertas de entrelazamiento como CNOT. La medición final del circuito colapsa el estado cuántico en un resultado clásico observable.

Quantum Machine Learning

El *Quantum Machine Learning* (QML) surge como la integración entre los principios del aprendizaje automático y la computación cuántica, con el objetivo de explotar las ventajas cuánticas en tareas de aprendizaje

y optimización. Este campo representa una evolución natural desde el Machine Learning clásico y el Deep Learning hacia modelos capaces de operar en espacios de características de alta dimensión.

Diversos enfoques han sido propuestos dentro del QML, entre los que destacan la *Quantum Support Vector Machine* (QSVM), las *Quantum Neural Networks* (QNNs) y los modelos variacionales. En particular, los modelos variacionales han cobrado relevancia debido a su compatibilidad con el hardware cuántico actual y su capacidad de integración con procesos de optimización clásica.

Variational Quantum Classifier

El *Variational Quantum Classifier* (VQC) es un modelo híbrido que combina circuitos cuánticos parametrizados con algoritmos de optimización clásicos. Su arquitectura se compone de tres elementos principales: un *feature map* cuántico encargado de codificar datos clásicos en estados cuánticos, un *ansatz* o circuito variacional entrenable que actúa como el mecanismo de aprendizaje, y un optimizador clásico que ajusta los parámetros del circuito.

Estudios previos han demostrado que los mapas de características cuánticos, como el *ZZFeatureMap*, permiten proyectar datos clásicos a espacios cuánticos donde las clases pueden volverse más separables. Asimismo, los circuitos variacionales han sido propuestos como modelos expresivos capaces de capturar correlaciones complejas en los datos, aprovechando el entrelazamiento cuántico.

Antecedentes y trabajos relacionados

Investigaciones como las de Benedetti et al. proponen el uso de circuitos cuánticos parametrizados como modelos de aprendizaje automático, estableciendo las bases teóricas de los enfoques variacionales. Por su parte, Havlíček et al. demostraron que los espacios de características cuánticos pueden ofrecer ventajas frente a los kernels clásicos en problemas de clasificación supervisada.

En el contexto aplicado, múltiples trabajos recientes han explorado la comparación entre modelos clásicos y cuánticos utilizando datasets estándar, como Iris, MNIST reducido y conjuntos de datos sintéticos, evidenciando que, si bien los modelos cuánticos actuales no superan sistemáticamente a los clásicos, sí presentan una capacidad real de aprendizaje y un potencial significativo a medida que el hardware cuántico evolucione.

En este proyecto, estos antecedentes se retoman mediante la implementación y evaluación comparativa de un clasificador cuántico variacional (VQC) frente a una SVM clásica, empleando un enfoque experimental reproducible que permite analizar de manera crítica el estado actual del aprendizaje automático cuántico.

Metodología

La metodología de este proyecto se basa en un enfoque experimental y comparativo, cuyo objetivo es analizar el desempeño de un modelo de aprendizaje automático cuántico frente a un modelo clásico bajo condiciones controladas. El estudio se desarrolla siguiendo un flujo de trabajo estructurado y reproducible, apoyado en una arquitectura híbrida cuántico-clásica.

En primer lugar, se definió el problema de clasificación y se estableció como objetivo principal la implementación de un *Variational Quantum Classifier* (VQC) y su comparación con un modelo clásico de referencia, una *Support Vector Machine* (SVM). Esta comparación se diseñó para evaluar tanto la capacidad de aprendizaje como las limitaciones actuales del enfoque cuántico.

El conjunto de datos seleccionado fue el dataset **Iris**, debido a su simplicidad y uso extendido en experimentos de aprendizaje automático. Para adecuarlo a las restricciones actuales de la computación cuántica, el dataset fue filtrado a dos clases (Setosa y Versicolor), resultando en un total de 100 muestras con cuatro características cada una. Esta reducción permitió optimizar el rendimiento en simuladores cuánticos, los cuales presentan un costo computacional elevado.

Antes del entrenamiento, los datos fueron sometidos a un proceso de preprocesamiento crítico. Se aplicó una normalización mediante *MinMaxScaler* al rango $[0, 1]$, ya que las puertas cuánticas operan con ángulos y amplitudes, y valores no normalizados pueden generar inestabilidad en los circuitos cuánticos. Posteriormente, el conjunto de datos se dividió en un 70% para entrenamiento y un 30% para prueba, manteniendo una división estratificada para conservar la proporción entre clases.

El modelo clásico se implementó utilizando una SVM con kernel RBF, la cual sirvió como línea base para la comparación. Este modelo permitió establecer un punto de referencia sólido en términos de precisión y tiempo de cómputo.

El modelo cuántico se construyó siguiendo una arquitectura variacional. En primer lugar, se utilizó un




FIGURE 1. Circuito cuántico variacional utilizado en la implementación del clasificador VQC.

ZZFeatureMap para codificar las cuatro características del dataset en estados cuánticos, aprovechando el entrelazamiento para proyectar los datos a un espacio cuántico de mayor dimensión. A continuación, se empleó un *ansatz* del tipo *RealAmplitudes*, compuesto por puertas de rotación parametrizadas y compuertas de entrelazamiento, el cual actúa como el componente entrenable del modelo. Finalmente, el entrenamiento del circuito variacional se realizó mediante el optimizador clásico *COBYLA*, seleccionado por ser libre de gradientes y adecuado para entornos con ruido.

La ejecución del modelo cuántico se llevó a cabo sobre un simulador cuántico ideal (*StatevectorSampler*), lo que implicó la simulación de estados cuánticos de dimensión exponencial y la evaluación repetida de circuitos durante el proceso de optimización.

Para la evaluación de los modelos se utilizaron métricas estándar de clasificación, tales como *accuracy*, *precision*, *recall* y *F1-score*, así como el análisis de matrices de confusión. Adicionalmente, se midió el tiempo de entrenamiento con el fin de comparar el costo computacional entre el enfoque clásico y el cuántico.

Finalmente, los resultados obtenidos fueron analizados de manera comparativa, permitiendo evaluar el grado de aprendizaje alcanzado por el modelo cuántico, sus limitaciones actuales frente al modelo clásico y su potencial futuro en escenarios de mayor complejidad.

Resultados y analisis

En esta sección se presentan y analizan los resultados obtenidos a partir de la comparación entre el modelo clásico basado en *Support Vector Machine* (SVM) y el modelo cuántico híbrido *Variational Quantum Classifier* (VQC), ambos entrenados y evaluados bajo las mismas condiciones experimentales.

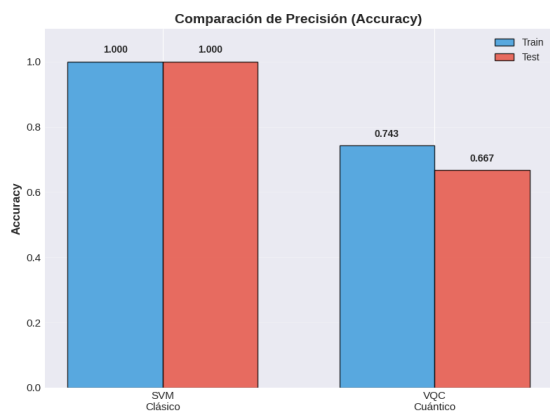


FIGURE 2. Comparacion de precisión

Resultados de precisión

En términos de precisión (*accuracy*), el modelo clásico SVM mostró un desempeño perfecto en el escenario evaluado. El SVM alcanzó una precisión del 100% tanto en el conjunto de entrenamiento como en el conjunto de prueba, lo que indica que las clases del dataset Iris filtrado son linealmente separables bajo el kernel RBF utilizado y que el modelo generaliza adecuadamente en este contexto.

Por otro lado, el modelo cuántico VQC obtuvo una precisión del 74.29% en el conjunto de entrenamiento y del 66.67% en el conjunto de prueba. Si bien estos valores son inferiores a los alcanzados por el modelo clásico, los resultados evidencian que el clasificador cuántico es capaz de aprender patrones reales a partir de los datos y realizar una clasificación significativamente mejor que una asignación aleatoria.

Análisis de matrices de confusión

El análisis de las matrices de confusión permite una comprensión más detallada del comportamiento de ambos modelos. En el caso del SVM clásico, la matriz de confusión muestra una clasificación perfecta, con 15 verdaderos positivos y 15 verdaderos negativos, sin la presencia de falsos positivos ni falsos negativos. Este resultado confirma la capacidad del modelo clásico para separar completamente ambas clases del conjunto de prueba.

En contraste, la matriz de confusión del VQC cuántico refleja un aprendizaje parcial. El modelo clasificó correctamente 20 de las 30 muestras del conjunto de prueba, con 10 verdaderos positivos y 10 verdaderos negativos. Sin embargo, se observaron 5 falsos positivos y 5 falsos negativos, distribuidos de manera simétrica entre ambas clases. Esta distribución




FIGURE 3. Matrices de confusión para SVM clásico y VQC cuántico.

sugiere que el modelo cuántico no presenta sesgo hacia una clase específica, pero su frontera de decisión resulta menos expresiva que la del modelo clásico en este escenario.

Tiempo de cómputo

El tiempo de entrenamiento representa uno de los aspectos más críticos en la comparación entre ambos enfoques. El modelo SVM clásico requirió aproximadamente 0.0029 segundos para su entrenamiento, evidenciando la eficiencia computacional de los algoritmos clásicos en problemas de pequeña escala.

En contraste, el entrenamiento del VQC cuántico demandó alrededor de 68.12 segundos, equivalente a aproximadamente 1.14 minutos. Esto implica que el modelo cuántico fue aproximadamente 23 535 veces más lento que el modelo clásico. Esta diferencia se debe principalmente a que el VQC fue ejecutado sobre




FIGURE 4. Comparación de tiempo de cómputo

un simulador cuántico clásico, el cual debe simular vectores de estado cuánticos de dimensión exponencial y evaluar múltiples circuitos en cada iteración del optimizador.

Discusión de resultados

Los resultados obtenidos evidencian que, en el contexto experimental evaluado, el modelo clásico supera al modelo cuántico tanto en precisión como en eficiencia computacional. No obstante, el desempeño del VQC demuestra que el enfoque cuántico no es aleatorio y posee una capacidad real de aprendizaje.

Las limitaciones observadas en el modelo cuántico están directamente relacionadas con el uso de simuladores cuánticos y con el estado actual del hardware cuántico. A pesar de ello, los resultados respaldan la validez del flujo de trabajo cuántico-clásico implementado y refuerzan la idea de que las arquitecturas híbridas representan el camino más realista para el desarrollo del aprendizaje automático cuántico en la actualidad.

Conclusiones y trabajos futuros

El presente proyecto permitió demostrar la aplicación práctica de la computación cuántica en el ámbito del aprendizaje automático mediante la implementación de un clasificador cuántico variacional (*Variational Quantum Classifier*, VQC) y su comparación directa con un modelo clásico de referencia basado en *Support Vector Machine* (SVM). Los resultados obtenidos evidencian que, bajo las condiciones experimentales evaluadas, el modelo clásico alcanza un desempeño superior en términos de precisión y tiempo de cómputo.

No obstante, el análisis de los resultados confirma

que el modelo cuántico híbrido es capaz de aprender patrones reales a partir de los datos y realizar una clasificación significativamente mejor que una asignación aleatoria. Este comportamiento se refleja en las métricas de desempeño y en la matriz de confusión del VQC, donde se observa un aprendizaje parcial sin sesgo hacia una clase específica. Estos hallazgos validan el correcto funcionamiento del flujo de trabajo cuántico-clásico implementado y demuestran que el aprendizaje automático cuántico es técnicamente viable en la actualidad.

Las principales limitaciones observadas están relacionadas con el elevado tiempo de cómputo del modelo cuántico, el cual se debe principalmente al uso de simuladores cuánticos clásicos y a la necesidad de simular estados cuánticos de dimensión exponencial. Esta restricción refleja el estado actual del hardware cuántico y pone de manifiesto que, en problemas de pequeña escala y baja complejidad, los modelos clásicos continúan siendo la opción más eficiente.

Como trabajos futuros, se propone extender este estudio a escenarios de mayor complejidad, explorando conjuntos de datos más grandes o con mayor número de clases, así como la evaluación del VQC en hardware cuántico real cuando sea posible. Asimismo, resulta relevante analizar el impacto de diferentes mapas de características, *ansatz* más profundos y optimizadores alternativos, con el fin de mejorar la capacidad expresiva del modelo cuántico. Finalmente, futuras investigaciones podrían centrarse en identificar dominios específicos donde las arquitecturas híbridas cuántico-clásicas ofrezcan ventajas reales frente a los enfoques clásicos, contribuyendo así a una evaluación más precisa del potencial del aprendizaje automático cuántico.

REFERENCES

1. M. Benedetti, E. Lloyd, S. Sack y M. Fiorentini, "Parameterized quantum circuits as machine learning models," *Quantum Science and Technology*, vol. 4, no. 4, p. 043001, 2019, doi: 10.1088/2058-9565/ab4eb5.
2. V. Havlíček, A. D. Córcoles, K. Temme, A. W. Harrow, A. Kandala, J. M. Chow y J. M. Gambetta, "Supervised learning with quantum-enhanced feature spaces," *Nature*, vol. 567, no. 7747, pp. 209–212, 2019.
3. E. Abbe, "Community detection and stochastic block models," *Journal of Machine Learning Research*, vol. 18, no. 177, pp. 1–86, 2018. [En línea]. Disponible: <https://www.jmlr.org/papers/v18/16-480.html>

4. S. Fortunato y D. Hric, "Community detection in networks: A user guide," *Physics Reports*, vol. 659, pp. 1–44, 2016, doi: 10.1016/j.physrep.2016.09.002.